

# Introducción al análisis cuantitativo de datos lingüísticos

## Bloque 3.2: Análisis de correlaciones

Ezequiel Koile (MPI-SSH)  
Carolina Gattai (IFIBA – CONICET)

# Hasta acá:

- ▶ Describimos variables numéricas y categóricas
- ▶ Comparamos dos grupos
  
- ▶ Siempre hemos hablado de *una sola variable*:
  - Medidas centrales + dispersión
  - Comparar estos valores entre grupos.

# ¿Y ahora?

- ▶ Estudiamos la relación *entre distintas variables*

## Correlación

- ▶ Dos variables están correlacionadas positivamente *sii tanto X como Y crecen y decrecen juntas.*
- ▶ Dos variables están correlacionadas negativamente *sii crecen en direcciones opuestas*
- ▶ Dos variables no están correlacionadas *sii el cambio en una no afecta el cambio en la otra.*

# Coeficientes de correlación

- ▶ Nos interesa definir un número que nos diga
  - Si existe una correlación entre dos variables
  - Cuán fuerte es esta
  - En qué dirección va (positiva o negativa)
- ▶ Vamos a definir
  - Un coeficiente paramétrico para variables intervalo o ratio con distribución normal
  - (Un coeficiente no paramétrico para los demás casos)
- ▶ *Elegimos* definir estos coeficientes de manera que:
  - Van de  $-1$  a  $+1$
  - $+1$  significa correlación positiva perfecta
  - $-1$  significa correlación negativa perfecta
  - $0$  significa variables no correlacionadas
- ▶ *¡¡NO RELACIONADOS CON SIGNIFICANCIA ESTADÍSTICA!!*

# Coeficiente de correlación de Pearson

- ▶ Definido como la covarianza entre ambas variables dividida por ambas desviaciones estándar

# Coeficiente de correlación de Pearson




Figure 6.2. Several possible values of Pearson product-moment correlation coefficient  $r$

Levshina 2015

# Coeficiente de correlación de Pearson

## PROS


- ▶ Si el tamaño de la muestra es moderado o grande y la población es normal bivariada, el CCP es el estimador de mayor verosimilitud (es decir, es imposible construir un coeficiente de correlación mejor que este)

# Coeficiente de correlación de Pearson

## CONTRAS

- ▶ Útil solo si la relación entre las variables es:
  - Monótona
  - Lineal

# Coeficiente de correlación de Pearson



Levshina 2015

# Coeficiente de correlación de Pearson

## CONTRAS

- ▶ Útil solo si la relación entre las variables es:
  - Monótona
  - Lineal
- ▶ Muy sensible a *outliers* (poco robusto)

# Coeficiente de correlación de Pearson




Figure 6.5. Impact of an outlier on the value of the Pearson  $r$

# Coeficiente de correlación de Pearson

## ¿Cuándo es estadísticamente significativo?

- ▶ La muestra se toma aleatoriamente de la población representada
- ▶ Ambas variables son al menos tipo intervalo
- ▶ Ambas variables forman una distribución normal bivariada y/o el tamaño de la muestra es grande (30 observaciones o más)
- ▶ **Homocedasticidad (homoscedasticity) en los residuos:** la relación entre las variables es de igual naturaleza a lo largo del rango de ambas variables.
- ▶ **Sin autocorrelación:** el valor de una variable no depende de su valor anterior o posterior

# Coeficiente de correlación de Pearson








Figure 6.7. Homoscedasticity (left) and heteroscedasticity (right)

Levshina 2015


# Coeficiente de correlación de Pearson



Four sets of data with the same PCC of  $r = 0.816$

Anscombe, Francis J. (1973) Graphs in statistical analysis. American Statistician, 27, 17-21.

# Coeficiente de correlación de Pearson




# Intensidad de la correlación (CCP)

- ▶  $r > 0.7$  (o  $r < -0.7$ ): Fuerte
- ▶  $0.3 > r > 0.7$  (o  $-0.7 < r < -0.3$ ): Moderada
- ▶  $-0.3 < r < 0.3$  : Débil

# Coeficientes de correlación no paramétricos


- ▶  $\rho$  de Spearman
- ▶  $\tau$  de Kendall

# Coeficientes de correlación no paramétricos




# ¿Cuándo usar cada CC?

Requisitos	$r$	$\rho$ or $\tau$
Muestras tomadas aleatoriamente de la población	Sí	Sí
Observaciones independientes	Sí	Sí
Sin autocorrelación	Sí	Sí
Variables al menos -----	intervalo	ordinales
Distribución normal subyacente (o $n > 30$ )	Sí	No
La relación es lineal	Sí	No
Homocedasticidad	Sí	No



# R-squared

- ▶ En este caso (una variable, relación lineal):
- ▶  $R^2 = r^2$



- ▶ Explicaciones copadas acá [StatQuest]:  
<https://youtu.be/2AQKmw14mHM>